

Co nám statistický test dovoluje tvrdit?

Od velikosti efektu k opatrnému vědeckému závěru

28. září 2026

Obsah

1	Měsíc ze sýra?	2
2	Co se dnes naučíme	3
3	Třináct slanisek, třináct průměrů	3
4	Co říká známá přímka?	8
4.1	Dobrá praxe: po každém modelu zkontrolujeme residua	11
4.2	Co znamená půl milimetru na stupeň?	13
5	Jeden odhad nestačí	14
6	Co kdyby ve skutečnosti žádný trend nebyl?	15
7	Jak daleko jsme od vodorovné přímky?	18
8	Malá odbočka: kolik volnosti zbývá?	19
8.1	Sudoku: kdy poslední volba přestane být volbou	19
8.2	Čtyři čísla s průměrem 10	20
8.3	Zpět ke krabům	21
8.4	Proč jsme s malým počtem lokalit opatrnější?	22
9	P-hodnota	24
9.1	Tři studenti čtou stejný výsledek	25
10	Když musíme udělat rozhodnutí	26
10.1	Kritické hodnoty	27
10.2	Stejnou otázku můžeme položit intervalu	30
11	Dva způsoby, jak se splést	32
11.1	Rychlá paměťová pomůcka	32
11.2	Biologický příklad: invazní druh	32
11.3	Když skutečný vztah přehlédneme	33
11.4	Vraťme se k síle: kolik studií vztah odhalí?	33
12	Co tedy můžeme říct o krabech?	35
12.1	Co se do jedné přímky nevešlo	36
13	Měsíc pořád není ze sýra	36
14	Příště budeme porovnávat skupiny	37
15	Co si odnést	37
	Slovníček pojmů	38

1 Měsíc ze sýra?

Představte si, že někdo pronese naprosto vážně:

Tvrzení, které budeme zkoumat

Měsíc je celý ze sýra.

Nejspíš se zasmějete. Přesto je na této větě něco užitečného: můžeme přemýšlet, jak bychom ji ověřovali. Mohli bychom zkoumat měsíční horniny, jejich složení nebo fyzikální vlastnosti.

Tvrzení je tedy **testovatelné**. To ale neznamená, že je **věrohodné**. Všechno, co už o Měsíci víme, mluví silně proti němu.

Zkuste si — Čtyři velmi rozdílná tvrzení

Nejprve si odpovězte sami. Potom rozbalte možné odpovědi a porovnejte s nimi svou úvahu:

1. Dá se věta zkoumat pomocí pozorování?
2. Je podle současných znalostí věrohodná?
3. Jaké pozorování by vás přimělo změnit názor?

Tvrzení

Měsíc je celý ze sýra

Všechny labutě jsou bílé

Holub stěhovavý vyhynul

Tento pták je nejkrásnější

Možné odpovědi

Tvrzení	Co lze pozorovat?	Co by silně změnilo závěr?
Měsíc je celý ze sýra	složení měsíčních hornin	důvěryhodný vzorek s vlastnostmi sýra
Všechny labutě jsou bílé	barvu nalezených labutí	jediná spolehlivě určená ne-bílá labuť
Holub stěhovavý vyhynul	přítomnost živých jedinců	jediný spolehlivě doložený živý jedinec
Tento pták je nejkrásnější	preferenze různých lidí	nejde o stejný druh empirického tvrzení

U vyhynulého holuba je navíc vidět důležitá nesymetrie. Nález živého jedince by závěr změnil okamžitě. Když žádného nenajdeme, jistota je menší: možná jsme hledali na špatném místě nebo jsme ho přehlédli.

Rychlá zastávka — Testovatelné neznamená pravděpodobné

Student řekne: „Když lze tvrzení o sýrovém Měsíci testovat, musíme ho brát stejně vážně jako geologické vysvětlení.“ Co se v jeho úvaze pokazilo?

Věda tedy není stroj, který po jednom pokusu vytiskne **pravda** nebo **nepravda**. Záleží také na kvalitě měření, uspořádání studie, předpokladech modelu, předchozích znalostech a výsledcích dalších studií.

Statistický test bude jen jedním dílkem tohoto většího obrazu.

2 Co se dnes naučíme

V této lekci budeme sledovat jedinou biologickou otázku od prvního grafu až k závěrečné větě. Po jejím prostudování dokážete:

- popsat, jak velký vztah jsme v datech našli a jak přesně jsme ho odhadli;
- vysvětlit, zda by podobně výrazný výsledek snadno vznikl i bez stálého trendu;
- rozeznat dva způsoby, kterými se při rozhodování můžeme splést;
- napsat závěr, který nepředstírá, že jeden test rozhodl vědeckou pravdu.

3 Třináct slanisek, třináct průměrů

Přesuňme se od Měsíce k otázce, u které odpověď předem neznáme:

Hlavní biologická otázka

Jsou samci atlantského kraba houslisty *Minuca pugnax* v průměru větší na severněji položených slaniskách?

Biologové si už dlouho všímají, že organismy bývají v chladnějších oblastech větší. Tomuto vzoru se říká Bergmannovo pravidlo. Neplatí automaticky pro každý druh a samo nevysvětluje, proč by měl případný vztah vznikat. Platí něco podobného i pro naše kraby?


V létě 2016 vědci navštívili slaniska mezi Floridou a Massachusetts. Pro každou lokalitu máme:

- její zeměpisnou šířku;
- počet změřených dospělých samců;
- průměrnou šířku jejich krunýře.

Každý řádek následující tabulky tedy představuje **jedno slanisko**. Naší jednotkou pozorování je proto slanisko, nikoli jednotlivý krab.

Lokalita	Šířka (° s. š.)	n	Průměr (mm)
GTM	30.0	28	12.40
SI	31.4	30	9.85
NIB	33.3	30	13.29
ZI	34.0	35	12.06
RC	34.7	25	12.49
VCR	37.2	30	16.34
DB	39.1	30	15.60
JC	39.6	30	15.27
CT	41.3	33	14.69
NB	41.6	29	17.14
CC	41.9	27	16.82
BC	42.2	37	16.20
PIE	42.7	28	18.50

Data pocházejí z výukového souboru [lterdatasampler::pie_crab](#), zveřejněného pod licencí CC0. Původní data jsou uložena v [Environmental Data Initiative](#) a související studie vyšla v časopise *Ecology and Evolution* ([Johnson et al., 2019](#)).



Obrázek 1: Každý oranžový bod představuje jedno ze třinácti sledovaných slanisek podél atlantického pobřeží USA. Souřadnice pocházejí z tabulky 1 související studie.

Doplňující — Odkud se vzalo třináct průměrů?

Při prvním čtení můžete všechny čtyři boxy „Doplňující“ přeskočit. Hlavní krabí příběh pokračuje obrázkem se všemi jedinci a třinácti průměry.

Původní tabulka obsahuje 392 jednotlivých krabů. Na každém slanisku bylo změřeno 25 až 37 samců. Pro hlavní analýzu jsme je zprůměrovali po lokalitách.

Data jsou přímo součástí balíčku `lterdatasampler`. Následující kód je načte, srozumitelně přejmenuje, vytvoří třináct průměrů a uloží obě výukové tabulky. V dalších částech lekce už načítáme připravené CSV soubory.

```

# Balíček stačí nainstalovat jednou:
# install.packages("lterdatasampler")

data("pie_crab", package = "lterdatasampler")

# Přejmenujeme sloupce tak, aby se s nimi v lekci dobře pracovalo.
data_krabi <-
  data.frame(
    datum = as.Date(pie_crab$date),
    zemepisna_sirka = pie_crab$latitude,
    kod_lokality = pie_crab$site,
    nazev_lokality = pie_crab$name,
    sirka_krunyre_mm = pie_crab$size
  )

# Pro každou lokalitu spočítáme průměrnou šířku krunýře.
data_prumery <-
  aggregate(
    sirka_krunyre_mm ~
      kod_lokality + nazev_lokality + zemepisna_sirka,
    data = data_krabi,
    FUN = mean
  )

# Zvlášť spočítáme počet změřených krabů na každé lokalitě.
data_pocty <-
  aggregate(
    sirka_krunyre_mm ~ kod_lokality,
    data = data_krabi,
    FUN = length
  )

```

Doplňující — Spojení průměrů a počtů

Průměry a počty teď spojíme do jedné tabulky s jedním řádkem pro každé slanisko. Nakonec uložíme jak jednotlivá měření, tak připravené průměry.

```

# Obě souhrnné tabulky spojíme podle kódu lokality.
data_lokality <-
  merge(
    x = data_prumery,

```

```

    y = data_pocty,
    by = "kod_lokalita",
    suffixes = c("_prumer", "_pocet")
  )

names(data_lokalita)[
  names(data_lokalita) == "sirka_krunyre_mm_prumer"
] <- "prumerna_sirka_mm"

names(data_lokalita)[
  names(data_lokalita) == "sirka_krunyre_mm_pocet"
] <- "pocet_krabu"

# Seřadíme lokality od jihu k severu a ponecháme potřebné sloupce.
data_lokalita <-
  data_lokalita[
    order(data_lokalita$zemepisna_sirka),
    c(
      "kod_lokalita",
      "nazev_lokalita",
      "zemepisna_sirka",
      "pocet_krabu",
      "prumerna_sirka_mm"
    )
  ]

```

Doplňující – Uložení výukových tabulek

Připravené tabulky uložíme jako CSV. Díky tomu může hlavní část lekce začít jednoduchým `read.csv()` a nemusí přípravu opakovat při každém renderu.

```

# Uložíme jednotlivé kraby i připravené průměry lokalit.
write.csv(
  data_krabi,
  file = here::here("data", "pie_crab.csv"),
  row.names = FALSE
)


write.csv(
  data_lokalita,
  file = here::here("data", "pie_crab_site_means.csv"),

```

```
row.names = FALSE
)
```

Doplňující — Jak vypadají všichni krabi?

Na obrázku jsou jednotliví krabi světle šedě. Velké body jsou průměry slanisek, které použijeme v modelu.



Obrázek 2: Jednotliví krabi sdílejí zeměpisnou šířku svého slaniska. Velké body zobrazují průměry použité v hlavním modelu.

Dnes proto pracujeme se 13 průměry lokalit. Proč nelze jednotlivé kraby bez dalšího považovat za 392 nezávislých odpovědí na otázku o zeměpisné šířce, probereme později u hierarchických dat.


4 Co říká známá přímka?

Než se podíváte — Jaký obrázek by podpořil naši domněnku?

Než si hodnoty zobrazíte v grafu, načrtněte si očekávaný obrázek.

- Co bude na vodorovné ose?
- Co bude na svislé ose?
- Jak by měly body vypadat, kdyby byli krabi na severu větší?
- Jaký vzor by naopak mluvil proti této představě?

Tedž už můžeme body opravdu zobrazit. Každý bod je průměr jednoho slaniska.



Obrázek 3: Průměrná šířka krunýře na sledovaných slaniskách. Oranžová přímka je jednoduchý lineární model.

Body směrem doprava převážně stoupají. Na severnějších lokalitách tedy mají krabi v průměru širší krunýře. Přímku fitujeme stejným příkazem `lm()`, který už znáte:

```
# Načteme tabulku s jedním řádkem pro každé slanisko
prumery_lokalit <-
  read.csv(
    file = here::here("data", "pie_crab_site_means.csv")
  )

# Fitujeme přímku přes průměry slanisek
mod_krabi <-
  lm(
    formula = prumerna_sirka_mm ~ zemepisna_sirka,
```

```

    data = prumery_lokalit
  )

# Zobrazíme celý přehled modelu.
summary(mod_krabi)

```

```

Call:
lm(formula = prumerna_sirka_mm ~ zemepisna_sirka, data = prumery_lokalit)

Residuals:
    Min       1Q   Median       3Q      Max
-1.77895 -0.74796  0.05101  0.73779  1.87228

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   -3.74716     3.00884   -1.245    0.239
zemepisna_sirka  0.48953     0.07948    6.159 7.11e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.226 on 11 degrees of freedom
Multiple R-squared:  0.7752,    Adjusted R-squared:  0.7548
F-statistic: 37.94 on 1 and 11 DF,  p-value: 7.112e-05

```

```

# Zobrazíme 95% intervaly spolehlivosti obou koeficientů.
confint(mod_krabi)

```

```

              2.5 %    97.5 %
(Intercept)  -10.3695640  2.8752446
zemepisna_sirka  0.3146022  0.6644593

```

V první tabulce už z předchozích lekcí umíme najít řádek se sklonem (*zemepisna_sirka*). Ve sloupci *Estimate* je jeho odhad 0.49 mm na stupeň. Vedle něj je známá standardní chyba 0.0795 mm na stupeň. Příkaz `confint()` pak ukazuje 95% interval od 0.315 do 0.664 mm na stupeň.


Model odhaduje také intercept. Ten by zde popisoval šířku krabů na rovníku, daleko mimo sledovaný rozsah, a pro naši biologickou otázku není zajímavý. Ve výpisu `summary()` zatím zůstávají dvě neznámé položky, *t value* a *Pr(>|t|)*. Právě k nim se v této lekci postupně dopracujeme.

4.1 Dobrá praxe: po každém modelu zkontrolujeme residua

Výpis koeficientů není konec práce. Stejně jako v minulé lekci se hned po fitování modelu podíváme na residua — rozdíly mezi pozorovanými průměry lokalit a hodnotami na přímce. Tuto kontrolu budeme dělat pokaždé, když fitujeme lineární model.

```
# Z modelu získáme residua a hodnoty odhadnuté přímkou.  
residua_krabi <- resid(mod_krabi)  
odhadnute_hodnoty <- fitted(mod_krabi)
```

Nejdříve zobrazíme rozdělení residuů. Hodnota nula znamená, že bod leží přesně na přímce; kladná a záporná residua leží na opačných stranách přímky.



Obrázek 4: Vyhlazený odhad rozdělení třinácti residuů krabiho modelu. Krátké čárky dole označují jednotlivé lokality.

Druhý graf vrací každé residuum k hodnotě odhadnuté modelem pro danou lokalitu. Hledáme body rozptýlené kolem nuly bez zřetelného oblouku nebo trychtýře.



Obrázek 5: Residua proti hodnotám odhadnutým modelem. Popisky umožňují spojit neobvyklé residuum s konkrétní lokalitou.

Přečtěte diagnostické grafy

- Jsou kladná i záporná residua zastoupena kolem nuly?
- Vidíte v grafu residuí proti odhadnutým hodnotám oblouk, trychtýř nebo jiný systematický vzor?
- Které lokality mají největší residua?
- Co můžeme z pouhých třinácti bodů posoudit jen velmi opatrně?

Grafy neukazují nápadný systematický vzor, ale třináct lokalit je málo pro sebevědomou diagnostiku tvaru rozdělení. Kontrola tedy neodhalila zřejmý problém; stále však musíme pamatovat na malý počet lokalit a jednoduchost modelu.

Stejný modelový výsledek budeme dále číst podmíněně: všechny následující závěry o velikosti vztahu a nejistotě předpokládají, že zvolená přímka, chování residuí a nezávislost lokalit jsou pro naši otázku přiměřené. Diagnostika nemůže dokázat správnost modelu, ale pomáhá odhalit zřetelný rozpor dříve, než začneme interpretovat další čísla z modelu.

Sklon 0.49 mm na jeden stupeň říká:

Význam sklonu v našem modelu


Podle fitované přímky je na lokalitě o 1° severněji průměrná šířka krunýře větší přibližně o 0.49 mm.

To je odpověď na otázku „o kolik?“. Takovému číselnému popisu změny říkáme efekt; v tomto modelu ho nejlépe vyjadřuje sklon v milimetrech na stupeň. V dalších krocích se budeme ptát, jak přesný odhad je a jak neobvyklý by byl, kdyby ve skutečnosti žádný vztah neexistoval.

4.2 Co znamená půl milimetru na stupeň?

Půl milimetru na jeden stupeň se těžko představuje. Co by takový sklon znamenal při cestě o pět stupňů na sever? A co mezi Floridou a Massachusetts?

- na 1°: 0.49 mm;
- na 5°: 2.45 mm;
- přes celý pozorovaný rozsah 12.7°: 6.22 mm.



Obrázek 6: Tentýž sklon přepočtený na 1°, 5° a celý rozsah sledovaných zeměpisných šířek.

Průměrné šířky krunýře se na slanskách pohybují přibližně mezi 9.9 a 18.5 mm. Rozdíl kolem 6.22 mm přes celé sledované pobřeží proto stojí za biologickou pozornost.

Zkuste si — Je to biologicky hodně?

1. Které měřítko se vám interpretuje nejsnáze: 1°, 5°, nebo celý rozsah?
2. Je změna přibližně 6.22 mm velká vzhledem k šířce krabů v tabulce?
3. Jakou další biologickou informaci byste potřebovali, abyste význam rozdílu posoudili lépe?

4. Mohla by studie najít velmi přesně změnu, která je biologicky zanedbatelná?


5 Jeden odhad nestačí

Sklon 0.49 mm na stupeň je náš nejlepší bodový odhad. Těchto třináct slanisek ale není jediných třináct, která jsme mohli navštívit. Jiný výběr by nejspíš dal trochu jiný sklon.

Právě proto jsme se v minulé lekci učili číst standardní chybu a interval spolehlivosti.

U krabího sklonu máme:

- odhad 0.49 mm na stupeň;
- standardní chybu 0.0795 mm na stupeň;
- 95% interval od 0.315 do 0.664 mm na stupeň.



Obrázek 7: Odhad sklonu a jeho 95% interval spolehlivosti.

Zastavte se u obrázku — Co všechno ještě připouští interval?

- Kde leží bodový odhad?
- Jaké malé i velké změny připouští celý interval?
- Jsou všechny biologicky stejně zajímavé?
- Co by pro naše sebevědomí znamenal mnohem širší interval?

Všechny hodnoty v intervalu popisují růst velikosti směrem na sever. Liší se v tom, jak rychlý by tento růst mohl být.

6 Co kdyby ve skutečnosti žádný trend nebyl?

Z modelu už známe velikost vztahu i nejistotu odhadu. Teď si k našemu výsledku postavíme jednu přesnou soupeřící možnost.

Představte si skeptickou kolegyni. Podívá se na graf a řekne:

Možná mezi zeměpisnou šířkou a průměrnou velikostí krabů v populaci žádný lineární vztah není. Těchto třináct bodů náhodou vyšlo rostoucích.

Jak by takový svět vypadal v našem modelu? Kdyby měla přímka sklon **nula**, průměrná velikost krabů by se při cestě na sever neměnila. To ale neznamená, že by všechny lokality měly úplně stejný průměr.

I ve světě bez severojižního trendu by mezi lokalitami zůstávaly rozdíly. Mohly by vznikat například:

- náhodným výběrem jiných krabů;
- nepřesností měření;
- místními podmínkami, které v modelu nemáme, třeba potravou nebo teplotou;
- dalšími biologickými rozdíly mezi slanisky.

Budeme tedy skládat simulovaná data ze dvou částí: **systematický sklon nastavíme na nulu**, ale kolem vodorovné přímky ponecháme **náhodnou variabilitu**.

Tuto druhou část už známe z diagnostiky modelu. Rozdíl mezi hodnotou lokality a hodnotou na přímce jsme nazvali residuum. V simulaci ke každé lokalitě vytvoříme nové náhodné residuum a přičteme ho k vodorovné přímce. Residua budou v průměru nulová, ale jednotlivě mohou být kladná i záporná. Jejich typickou velikost nastavíme podle reziduální směrodatné odchylky našeho krabího modelu, přibližně 1.23 mm.

Právě tato simulovaná residua způsobí, že přímka fitovaná jednomu náhodnému souboru nemusí vyjít přesně vodorovná — stejně jako skutečná residua způsobují, že třináct pozorovaných bodů neleží přesně na fitované přímce.

Porovnáváme tedy dvě možnosti:

Možnost	Co říká o krabech
Nulová možnost	Průměrná velikost se se zeměpisnou šířkou lineárně nemění. Sklon je 0 mm na stupeň.
Alternativní možnost	Průměrná velikost se se zeměpisnou šířkou lineárně mění. Sklon není 0 mm na stupeň.

Nula se zde nevzala z obecného statistického pravidla. Patří k naší konkrétní otázce: v lineárním modelu znamená sklon 0 přesně **žádnou změnu průměrné velikosti při cestě na sever**.

Teprve teď tuto dvojici zapíšeme zkráceně. Symbol $\beta_{\text{šířka}}$ označuje sklon vztahu v širší populaci lokalit, který se snažíme odhadnout pomocí našich třinácti slanisek:

$$H_0 : \beta_{\text{šířka}} = 0 \quad \text{a} \quad H_A : \beta_{\text{šířka}} \neq 0$$

Nulová hypotéza H_0 je právě nulová možnost z tabulky. Alternativní hypotéza H_A připouští růst i pokles.


Nulová hypotéza tedy **neříká**, že každý soubor třinácti slanisek musí dát odhad sklonu přesně nula. Říká, že dlouhodobý systematický trend je nulový. Náhodná variabilita kolem něj může v jednotlivém souboru vytvořit mírně rostoucí i mírně klesající přímku.

Tento nulový svět teď prozkoumáme simulací. Ponecháme stejných třináct zeměpisných šířek. Pro každou z nich vygenerujeme průměrnou velikost jako **stejnou základní úroveň plus nové náhodné residuum**. V simulaci tedy není žádný systematický růst k severu, ale lokality se stále liší. Každému novému souboru potom fitujeme přímku.

Předpovězte výsledek simulace


- Budou všechny odhadnuté sklony přesně nulové?
- Kolem jaké hodnoty se budou shlukovat?
- Mohou občas vzniknout i výrazně kladné nebo záporné sklony?
- Kam by asi patřil náš sklon 0.49 mm na stupeň?

Zkusme si taková data vyrobit. Všechny lokality dostanou stejnou očekávanou velikost, takže vložený sklon je nula. Ke každé lokalitě ale přidáme nové residuum podobně velké jako residua kolem skutečné krabí přímky. Nejprve se podíváme na dvacet takových náhodných studií.



Obrázek 8: Dvacet náhodných studií vytvořených ve světě s nulovým sklonem. Od vodorovné přímky jsme ke každé lokalitě přičetli nové náhodné residuum. Každá studie obsahuje třináct bodů a vlastní fitovanou přímku.

Přestože jsme žádný trend nevložili, některé přímky stoupají a jiné klesají. Náhoda tedy dokáže vytvořit nenulový odhad. Teď stejnou studii zopakujeme pět tisíckrát a místo všech bodů si z každé ponecháme jen odhadnutý sklon.



Obrázek 9: Sklony z pěti tisíc simulovaných souborů, ve kterých byl skutečný sklon nulový. Oranžová čára ukazuje pozorovaný sklon.

Většina sklonů leží blízko nuly. Náš pozorovaný sklon je daleko vpravo. Abychom mohli říct **jak daleko**, potřebujeme vzdálenost vyjádřit vzhledem k nejistotě odhadu.

7 Jak daleko jsme od vodorovné přímky?

Nejprve si sepišeme známá čísla:

Co známe	Hodnota
Pozorovaný sklon (Estimate)	0.490 mm na 1°
Sklon vodorovné přímky (null value)	0 mm na 1°
Rozdíl od nuly (Estimate – null value)	0.490 mm na 1°
Standardní chyba sklonu (Std. Error)	0.0795 mm na 1°

Otázka zní: **Kolikrát se standardní chyba vejde do vzdálenosti mezi naším sklonem a nulou?**

$$\frac{\text{pozorovaný sklon} - \text{nulový sklon}}{\text{standardní chyba sklonu}}$$

Dosadíme:

$$\frac{0.490 - 0}{0.0795} \approx 6.16.$$

Náš sklon tedy leží přibližně 6.16 standardních chyb od nuly.

Statistici tuto vzdálenost označují písmenem t . Stejný výpočet se obecně zapisuje:

$$t = \frac{\hat{\beta} - \beta_0}{SE(\hat{\beta})}.$$

Symbol $\hat{\beta}$ označuje odhadnutý sklon, β_0 porovnávanou nulovou hodnotu a $SE(\hat{\beta})$ standardní chybu odhadu.

Zkuste si — Spočítejte t a řekněte, co znamená

1. Odečtete nulový sklon od pozorovaného.
2. Vydělíte rozdíl standardní chybou.
3. Doplňte větu: „Pozorovaný sklon leží přibližně ..“
4. Vysvětlíte, proč t -statistika není velikostí biologického efektu.

T -statistika je **standardizovaná vzdálenost od jedné konkrétní hodnoty**. Velké $|t|$ může vzniknout velkým efektem, vysokou přesností, nebo obojím.

8 Malá odbočka: kolik volnosti zbývá?

Stejná hodnota t není stejně neobvyklá ve studii se čtyřmi body a ve studii se čtyřmi tisíci body. Při malém množství informace odhadujeme šum méně stabilně a musíme být opatrnější.

Tuto „zbývající informaci“ popisují stupně volnosti.

8.1 Sudoku: kdy poslední volba přestane být volbou

Statistické stupně volnosti si zkusíme ilustrovat pomocí Sudoku. Sudoku je hlavolam s mřížkou 9×9 polí. Mřížka je rozdělena na devět menších čtverců 3×3 . Číslice 1 až 9 se musí objevit právě jednou v každém řádku, sloupci i malém čtverci.

Podívejme se jen na jeden čtverec 3×3 . Vlevo známe tři číslice a pro prázdná pole ještě zbývá mnoho možností. Vpravo už jsou umístěny číslice 1 až 8. Poslední pole nemá na výběr: musí v něm být 9.

Málo čísel: mnoho možností			Osm čísel: poslední je vynucené		
1			1	2	3
	4		4	5	6
		7	7	8	?

Obrázek 10: V neúplném čtverci zbývá mnoho možností. Po umístění osmi různých čísel je poslední hodnota vynucená.

Statistické stupně volnosti jsou trochu podobné této situaci v Sudoku: říkájí nám, **kolik volnosti k volbě ještě zbývá**, když už platí určitá omezení. Sudoku tuto myšlenku dobře zviditelní, i když jeho pravidla nejsou statistickým výpočtem.

8.2 Čtyři čísla s průměrem 10

Nejdříve slovy: požadovaný součet získáme jako **počet čísel krát jejich pevný průměr**. Chceme 4 čísla s průměrem 10, takže jejich součet musí být 4 krát 10, tedy 40.

$$\text{požadovaný součet} = \text{počet čísel} \times \text{pevný průměr}.$$

Nejdříve zvolíme tři čísla. Poslední už musí doplnit součet do 40:

$$7 + 12 + 9 + x = 40$$

$$x = 40 - 7 - 12 - 9 = 12.$$

Co když známe jen první dvě čísla?

$$7 + 12 + x + y = 40$$

Teď neznáme ani x , ani y . Z jediné rovnice je neumíme oba určit: x si ještě můžeme zvolit a teprve potom je y vynuceno tak, aby součet zůstal 40. Ve srovnání s prvním příkladem tedy zbývá **o jednu volbu více**.

Nejde nám o vyřešení rovnice. Sledujeme, kolik hodnot ještě můžeme zvolit nezávisle a kolik jich už musí splnit omezení pevného součtu.

Zkuste vlastní čtveřici

Napište tři libovolná čísla a sestavte rovnici pro čtvrté tak, aby jejich průměr byl 10. Kolik hodnot jste mohli zvolit nezávisle? Která hodnota už byla vynucená?

Pro čtyři čísla s pevným průměrem platí:

$$\text{stupně volnosti} = \text{počet čísel} - \text{jedno omezení}$$

$$df = 4 - 1 = 3.$$

První tři čísla mohou být zvolena volně. Jakmile známe je a požadovaný průměr, čtvrté musí doplnit součet do 40.

Obecně pro n čísel s jedním pevným průměrem platí:

$$df = n - 1,$$

kde n je počet čísel a jednička představuje jedno omezení jejich součtu.

8.3 Zpět ke krabům

Krabí model má 13 průměrů slanisek. To je náš počet pozorování. Z těchto pozorování model odhaduje dvě hodnoty:

- intercept;
- sklon.

Po odhadu těchto dvou koeficientů zbývá:

residuální stupně volnosti = počet pozorování (zde počet lokalit) – počet odhadnutých koeficientů

$$df = 13 - 2 = 11.$$

Stejný vztah můžeme pro lineární model zapsat obecně:

$$df_{\text{res}} = n - p,$$

kde n je počet pozorování – u krabů počet lokalit – a p je počet koeficientů odhadnutých z těchto pozorování. Zde tedy $n = 13$ a $p = 2$.

Spojte tři obrazy – Kde přesně analogie končí?

Doplňte tři věty:

1. Sudoku ukazuje, že ...
2. Čtyři čísla s pevným průměrem ukazují přesněji, že ...
3. V regresi odhad interceptu a sklonu znamená, že ...

Teď si spojíme počet pozorování s tím, kolik volnosti po fitování přímky zbývá. Přímka pokaždé odhaduje dva koeficienty, intercept a sklon:

Počet nezávislých pozorování	Odhadnuté koeficienty	Zbývající residuální df
3	2	1
13	2	11
10 002	2	10 000

Sudoku ukázalo volnost, která zbývá při postupném doplňování hodnot. Příklad s pevným průměrem ukázal stejnou myšlenku přesnou rovnicí. V regresi spotřebujeme část informace na odhad interceptu a sklonu. Když přidáme další nezávislá pozorování, ale stále odhadujeme jen tyto dva koeficienty, zbývá více residuálních stupňů volnosti.


8.4 Proč jsme s malým počtem lokalit opatrnější?

Pro vyhodnocení t -statistiky používáme t -rozdělení. Křivka ukazuje, které hodnoty t bychom při opakování studie čekali častěji a které méně často. **Celá plocha pod křivkou představuje všechny možné výsledky dohromady.**

Nejdříve si vybereme dobře viditelnou hranici: hodnoty alespoň dvě standardní chyby od nuly, tedy $t \leq -2$ nebo $t \geq 2$. Fialová plocha ukáže, jak velká část možných výsledků leží za těmito hranicemi.

Pouze ilustrační příklad — ještě ne krabí výsledek

Hodnotu $|t| = 2$ jsme zvolili jen proto, aby byly vybarvené plochy dobře vidět. **Není to naše krabí t -statistika ani výsledek krabího modelu.** Obrázek zatím slouží pouze k porovnání ploch při různých stupních volnosti. Co přesně tato plocha znamená, pojmenujeme v následující části.



Obrázek 11: Ilustrační hranice $t = -2$ a $t = 2$ nejsou výsledkem krabího modelu. Ukazují pouze, že při menším df zůstává za stejnými hranicemi větší část celkové plochy.

Přečtěte plochu pod křivkou

- Co představuje celá plocha pod jednou křivkou?
- Co představují dvě fialové části?
- U které křivky zabírají fialové části největší podíl celku?
- Co se s fialovou plochou mění, když roste počet stupňů volnosti?

Při malém df zůstává dále od nuly větší část celkové plochy. Teprve teď pro tento tvar zavedeme běžný název: statistici říkají, že taková křivka má **těžší chvosty**. Velké absolutní hodnoty t proto nejsou při malém df tak neobvyklé. Krabí model má 11 stupňů volnosti, takže v následující části použijeme tvar prostřední křivky — už ale s naší skutečnou hodnotou t , nikoli s ilustrační hranicí 2.

9 P-hodnota


Vraťme se ke krabům. Nulová hypotéza popisuje svět, ve kterém je sklon opravdu nulový. T-křivka s stupni volnosti 11 ukazuje, jaké hodnoty t by v takovém světě vznikaly při opakování studie.

Pozorovaný sklon leží přibližně 6.16 standardních chyb od nuly. Odpovídající t-statistika je tedy $t \approx 6.16$. Teď se ptáme, **jaká část nulového referenčního rozdělení leží alespoň tak daleko od nuly jako náš výsledek**.

Celá plocha pod t-křivkou představuje všechny možné hodnoty t v nulovém světě a má velikost 1. Hledaná část této plochy proto musí být číslo mezi 0 a 1.

Co hledáme?	V krabím modelu
Hranice stejně vzdálené od nuly	$t = -6.159$ a $t = +6.159$
Výsledky ještě vzdálenější	vše nalevo od záporné hranice a napravo od kladné hranice
Proč oba směry?	alternativa připouští kladný i záporný vztah

Obě krajní oblasti se nazývají **chvosty rozdělení**. Protože naše otázka připouští kladný i záporný sklon, budeme počítat plochu v obou chvostech.



Obrázek 12: Fialové pásy označují hodnoty t alespoň tak vzdálené od nuly jako pozorované t . Hledaný podíl tvoří plocha pod křivkou uvnitř obou pásů.

Najděte obě hledané plochy

Na obrázku najděte:

1. pozorovanou kladnou t-statistiku;
2. stejně vzdálenou zápornou hodnotu;
3. všechny hodnoty alespoň tak extrémní vpravo;
4. všechny hodnoty alespoň tak extrémní vlevo.

Proč by vybarvení jen pravého chvostu neodpovídalo otázce, která připouští růst i pokles?

Sečteme plochu v levém a pravém chvostu. **Tomuto součtu se ve statistice říká p-hodnota.**

P-hodnota v jedné větě

Pokud by nulová hypotéza a předpoklady modelu platily, p-hodnota je pravděpodobnost, že získáme t-statistiku alespoň tak vzdálenou od nuly, jako je ta naše. Je to plocha pod referenční křivkou, a proto nabývá hodnot **od 0 do 1**.

Co z p-hodnoty můžeme přímo přečíst?

- **Vždy leží mezi 0 a 1.** Nula by znamenala žádnou plochu, jednička celou plochu pod křivkou.
- **Je podmíněná nulovým světem a modelem.** Nejde o pravděpodobnost, že je nulová hypotéza pravdivá.
- **U oboustranné otázky zahrnuje oba chvosty.** Počítáme kladné i záporné výsledky alespoň tak vzdálené od nuly.
- **Čím menší je p-hodnota, tím méně jsou data slučitelná s přesně nulovým sklonem.** Takto krajní výsledek by v nulovém světě vznikl méně často.

Pro krabí model je tento součet přibližně 0.000071. Kdyby byl skutečný sklon nulový a model správně popisoval vznik dat, takto krajní nebo ještě krajnější t-statistika by se objevila přibližně 7,1 krát ze 100 000 opakování.

9.1 Tři studenti čtou stejný výsledek

Anna: „P-hodnota 0,000071 znamená, že pravděpodobnost nulové hypotézy je 0,000071.“

Boris: „Tak malá p-hodnota znamená, že biologický efekt musí být obrovský.“

Cyril: „Kdyby byl skutečný sklon nulový a platil náš model, takto krajní výsledek by byl velmi vzácný.“

Kdo výsledek čte správně?

Který student je nejbližší správné interpretaci? U zbývajících dvou přesně pojmenujte chybu. Co musí i správná věta přiznat o předpokladech modelu?

Cyril jako jediný odpovídá na otázku, kterou p-hodnota skutečně klade.

Co p-hodnota neříká

Škrtněte následující nesprávné výklady. P-hodnota není:

- pravděpodobnost, že H_0 je pravdivá;
- pravděpodobnost, že alternativní hypotéza je pravdivá;
- velikost biologického efektu;
- pravděpodobnost, že výsledek vznikl „náhodou“;
- pravděpodobnost úspěšného zopakování studie;
- kontrola správnosti všech předpokladů;
- konečný verdikt o Bergmannově pravidle.

Doplňující: jedna předem položená otázka a mnoho vyzkoušených otázek

Naše p-hodnota odpovídá jedné předem pojmenované otázce o sklonu vůči zeměpisné šířce. Kdybychom však ze stejných dat bez předem daného plánu položili mnoho souvisejících otázek, zvýšila by se šance, že alespoň jedna analýza vytvoří nápadně malou p-hodnotu i bez přesvědčivého biologického signálu.

Proto k interpretaci patří také informace, kolik otázek výsledku předcházelo a zda byly zvoleny před pohledem na výsledky. Předem formulovaná biologická otázka omezuje hledání výsledku, který pouze vypadá zajímavě. V následující lekci uvidíme, jak se stejné riziko objeví, když z jedné dat položíme několik souvisejících otázek.

10 Když musíme udělat rozhodnutí

P-hodnota popisuje, nakolik jsou data slučitelná s nulovou hypotézou. V některých situacích ale musíme udělat také **rozhodnutí**: nulovou hypotézu zamítnout, nebo ji nezamítnout. K tomu potřebujeme pravidlo zvolené ještě před pohledem na výsledek.

Představme si mnoho studií, ve kterých nulová hypotéza opravdu platí. Jak často jsme ochotni připustit, že ji naše pravidlo přesto omylem zamítneme? Hodnota 5 % například znamená, že při mnoha opakovaných studiích se stejným pravidlem připouštíme pětiprocentní dlouhodobé riziko falešného zamítnutí pravdivé nulové hypotézy.

Tato předem zvolená hranice se nazývá hladina významnosti a označuje se řeckým písmenem α (alfa). Často se používá:

- 5 %, tedy $\alpha = 0,05$;

- v přísněji nastavených analýzách například 1 %, tedy $\alpha = 0,01$.

Ani 5 %, ani 1 % není přírodní zákon. Hranice má vycházet z pravidel oboru a z následků nesprávného rozhodnutí. Dva možné způsoby, jak se při takovém rozhodování splést, pojmenujeme v následující části.

10.1 Kritické hodnoty

Plochu pod t-křivkou ani její přesné hranice není snadné vypočítat ručně. Proto statistické učebnice před běžným používáním počítačů obsahovaly několik stran předem vypočtených tabulek. Z nich se vyhledávala kritická hodnota pro zvolené rozdělení, hladinu významnosti a stupně volnosti.

Tabulka tedy nepočítala přesnou plochu znovu pro každý model. Umožnila jednodušší postup: najít správnou hranici a porovnat s ní pozorovanou testovou statistiku. Pokud $|t|$ leželo za kritickou hodnotou, odpovídalo to p-hodnotě nejvýše α a výsledek se označil jako statisticky významný. Podrobnější tabulky také dovolovaly p-hodnotu zařadit mezi dvě uvedené hranice, ale obvykle nedaly tolik desetinných míst jako dnešní software.

Nebyla to jedna hranice pro všechny modely. Bylo potřeba zvolit:


- referenční rozdělení — zde t-rozdělení;
- oboustrannou hladinu významnosti — zde $\alpha = 0,05$;
- správný řádek podle stupňů volnosti — zde $df = 11$.

Malá část takové tabulky by vypadala následovně. Hodnoty říkají, jak daleko od nuly začíná při oboustranné hladině 5 % krajních pět procent t-rozdělení.

Reziduální stupně volnosti	Kritická hodnota $ t $ pro $\alpha = 0,05$
11 — krabí model	2.201
10 000	1.96

V řádku pro 11 stupňů volnosti najdeme hranice přibližně -2.201 a $+2.201$. Pozorované krabí $|t| = 6.159$ leží daleko za nimi.

Teď stejné hranice přidáme přímo do známého t-rozdělení. Fialová vyznačuje předem zvolené kritické oblasti; oranžová ukazuje výsledek našeho modelu.



Obrázek 13: Kritické hranice a pozorovaná t-statistika v nulovém t-rozdělení. Fialové chvosty mají dohromady plochu alfa; oranžové hranice vymezují oboustrannou p-hodnotu.

Fialové chvosty za kritickými hranicemi mají dohromady plochu $\alpha = 0,05$. Skutečně pozorovaná t-statistika je kladná; záporná oranžová hranice je pouze její zrcadlový protějšek pro oboustrannou otázku. P-hodnota je plocha pod t-křivkou za oběma oranžovými hranicemi. Protože $|t| = 6.159$ leží za kritickou hodnotou 2.201, vedou porovnání $|t|$ s kritickou hodnotou a porovnání p-hodnoty s α ke stejnému rozhodnutí.

Dnes stejnou hodnotu vyhledá R funkcí `qt()`. Funkce `pt()` pak spočítá plochu za pozorovaným t , tedy p-hodnotu. Následující kód používá přímo model, který jsme už fitovali:

```
# Hranici spočítáme pro alfa = 0,05 a df našeho modelu.
kriticke_t <- qt(p = 1 - 0.05 / 2, df = df.residual(mod_krabi))

# t-statistiku přečteme z výpisu modelu.
t_krabi <- coef(summary(mod_krabi))["zemepisna_sirka", "t value"]

# Obě krajní plochy t-rozdělení sečteme.
p_krabi <- 2 * pt(q = -abs(t_krabi), df = df.residual(mod_krabi))

c(
  kriticka_hodnota = kriticke_t,
  t_krabi = t_krabi,
```

```
p_hodnota = p_krabi
)
```

kriticka_hodnota	t_krabi	p_hodnota
2.200985e+00	6.159372e+00	7.112446e-05

```
abs(t_krabi) > kriticke_t
```

```
[1] TRUE
```

V dnešní analýze se o ruční vyhledávání kritických hodnot ani o výpočet pomocí `qt()` a `pt()` nemusíme starat. R už test koeficientu provedl při fitování modelu. Podívejme se znovu na známý výpis:

```
# Znovu zobrazíme celý souhrn stejného modelu.
summary(mod_krabi)
```

```
Call:
lm(formula = prumer_na_sirka_mm ~ zemepisna_sirka, data = prumery_lokalit)

Residuals:
    Min       1Q   Median       3Q      Max
-1.77895 -0.74796  0.05101  0.73779  1.87228

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   -3.74716     3.00884  -1.245    0.239
zemepisna_sirka  0.48953     0.07948   6.159 7.11e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.226 on 11 degrees of freedom
Multiple R-squared:  0.7752,    Adjusted R-squared:  0.7548
F-statistic: 37.94 on 1 and 11 DF,  p-value: 7.112e-05
```

P-hodnotu pro naši biologickou otázku najdeme v tabulce `Coefficients`:

- vybereme řádek `zemepisna_sirka`, protože právě ten obsahuje sklon vztahu k zeměpisné šířce;
- ve sloupci `t value` vidíme pozorovanou t-statistiku 6.159;
- ve sloupci `Pr(>|t|)` vidíme oboustrannou p-hodnotu 0.000071;

- počet reziduálních stupňů volnosti 11 najdeme níže ve výpisu na řádce **Residual standard error**.

To je hodnota, kterou budeme při běžné práci číst. Tabulka kritických hodnot, porovnání s $|t|$ a porovnání p-hodnoty s α jsou jen tři zápisy stejného rozhodovacího pravidla. Počítač princip porovnání nezměnil; dnes však stejné hranice a plochy vypočítá za nás.

Teprve po volbě hranice porovnáme p-hodnotu s α :

Výsledek porovnání	Běžné rozhodnutí a označení
p-hodnota je nejvýše α	zamítneme nulovou hypotézu ; výsledek označíme jako statisticky významný
p-hodnota je větší než α	nulovou hypotézu nezamítneme ; výsledek není na zvolené hladině statisticky významný

V těchto materiálech používáme český termín **statisticky významný**. V článcích často uvidíte také synonymum **statisticky signifikantní** (anglicky *statistically significant*). P-hodnota je v obou případech menší než předem zvolená rozhodovací hranice.

Statisticky významný neznamená biologicky důležitý

Slovo „významný“ zde **neříká**, že je efekt velký, biologicky důležitý nebo určitě pravdivý. O biologickém významu rozhodujeme podle velikosti efektu v jeho jednotkách a podle biologického kontextu, nikoli podle samotného porovnání p-hodnoty s hranicí.


U krabů je p-hodnota 0.000071. Při $\alpha = 0,05$ proto nulovou hypotézu o přesně nulovém sklonu zamítáme a výsledek nazveme statisticky významným. Odpovídající 95% interval spolehlivosti nulu neprotíná, takže vede ke stejnému rozhodnutí. Neříkáme tím, že jsme alternativní hypotézu dokázali; říkáme, že přesně nulový sklon je za předpokladů modelu s výsledkem velmi obtížně slučitelný.

10.2 Stejnou otázku můžeme položit intervalu

Teď už víme, proč porovnááme právě 95% interval s hladinou $\alpha = 0,05$. U oboustranného testu patří k sobě:

- kritické hranice vymezující prostředních 95 % příslušného referenčního rozdělení;
- 95% interval spolehlivosti vytvořený pomocí stejných hranic;
- zbývajících 5 % rozdělených mezi oba chvosty;
- rozhodovací hranice $\alpha = 0,05$.

Stejnou otázku proto můžeme položit bez dalšího výpočtu p-hodnoty: **obsahuje 95% interval spolehlivosti nulový sklon?**



Obrázek 14: Odhad sklonu a jeho 95% interval spolehlivosti. Svislá čára označuje nulový sklon, tedy žádnou lineární změnu k severu.

Krabí interval od 0.315 do 0.664 mm na stupeň nulu neprotíná. Při oboustranné hladině $\alpha = 0,05$ proto vede ke stejnému rozhodnutí jako p-hodnota: nulový sklon zamítneme. Kdyby 95% interval nulu protínal, p-hodnota by při stejném modelu nebyla menší než 0,05 a nulovou hypotézu bychom nezamítli.

Interval nám přitom ukazuje víc než samotné rozhodnutí. Vidíme z něj také rozsah kladných velikostí vztahu, které zůstávají slučitelné s daty a modelem.

Nezamítnout nulovou hypotézu naopak neznamená dokázat, že efekt je přesně nula.

Doplňující: nula nemusí být biologicky nejdůležitější hranice

Nulový sklon je matematicky jednoduchá referenční hodnota, ale biologická otázka může mít důležitější hranici. Výzkumníci mohou například předem určit, jak velký kladný sklon šířky krunýře na jeden stupeň je ještě biologicky zanedbatelný a od jaké velikosti už by měnil jejich biologický závěr. Konkrétní hranice musí vycházet z biologických znalostí a měla by být zdůvodněna před čtením výsledku.

Interval spolehlivosti můžeme porovnat nejen s nulou, ale také s takovou předem zvolenou hranicí. Může například celý ležet pod hranicí biologicky důležitého kladného sklonu, i když obsahuje nulu; v takovém případě mezi hodnotami slučitelnými s daty a modelem není velký kladný efekt, ale interval neříká automaticky totéž o opačném směru. Jindy může interval připouštět nulový i biologicky významný kladný efekt. Formální testy ekvivalence patří do pokročilejšího kurzu; zde stačí číst celý rozsah efektů slučitelných s daty.

11 Dva způsoby, jak se splést

Rozhodovací pravidlo už máme: p-hodnotu porovnáme s předem zvolenou hladinou významnosti. Rozhodnutí ale není totéž co jistota. Může odpovídat skutečnosti, nebo se můžeme splést dvěma různými způsoby.

11.1 Rychlá paměťová pomůcka

U těhotenského testu si představme nulový stav „těhotenství není přítomno“:

- **chyba I. druhu neboli falešně pozitivní výsledek:** test hlásí těhotenství v očividně nemožné situaci;
- **chyba II. druhu neboli falešně negativní výsledek:** test nehlásí těhotenství v očividně pokročilé fázi.



(a) Falešně pozitivní výsledek: zjevně netěhotný muž překvapeně drží pozitivní těhotenský test.



(b) Falešně negativní výsledek: zjevně těhotná žena překvapeně drží negativní těhotenský test.

Obrázek 15: Dvě úmyslně absurdní situace jako paměťová pomůcka: vlevo chyba I. druhu, vpravo chyba II. druhu.

Je to úmyslně absurdní zkratka. Skutečná definice vždy závisí na tom, jak jsme určili nulový stav.

- **Chyba I. druhu:** zamítneme nulovou hypotézu, přestože je pravdivá. Jde o falešně pozitivní závěr neboli falešný poplach. Předem zvolená hladina významnosti α určuje dlouhodobé riziko právě této chyby.
- **Chyba II. druhu:** nulovou hypotézu nezamítneme, přestože ve skutečnosti neplatí a existuje skutečný efekt.

11.2 Biologický příklad: invazní druh

Představme si průzkum, jehož nulová hypotéza zní:

$$H_0 : \text{invazní druh v oblasti není přítomen} .$$

Skutečnost	Průzkum hlásí „nepřítomen“	Průzkum hlásí „přítomen“
Druh není přítomen	správné rozhodnutí	chyba I. druhu: zbytečný zásah
Druh je přítomen	chyba II. druhu: přehlédnutí invaze	správné rozhodnutí

Rozhodněte — Která chyba je horší?

1. Zařadte oba těhotenské příklady jako chybu I. nebo II. druhu.
2. Totéž udělejte pro invazní druh.
3. Která chyba může být v ochraně přírody závažnější?
4. Jak odpověď závisí na ceně zásahu, rychlosti šíření a vratnosti škod?

Žádný typ chyby není vždy horší. Záleží na následcích.

U krabího modelu by chyba I. druhu znamenala, že tvrdíme vztah, přestože je populační sklon nulový. Chyba II. druhu by znamenala, že skutečný vztah neodhalíme.

11.3 Když skutečný vztah přehlédneme

Chyba II. druhu popisuje jednotlivý omyl. Zbývá ale praktická otázka: **Jak dobře je naše studie připravena skutečný vztah vůbec odhalit?** Této schopnosti říkáme **síla testu**.

V tomto kontextu znamená „efekt“ vždy **předem zvolenou skutečnou velikost efektu** (*effect size*) v širší populaci — například skutečný sklon 0,25 mm na stupeň. Nejde o pravděpodobnost, že efekt existuje, ani o dodatečné přejmenování sklonu, který jsme právě pozorovali.

Kdybychom opakovali stejně navrženou studii ve světě s touto konkrétní skutečnou velikostí efektu, síla testu by byla podíl opakování, ve kterých bychom nulovou hypotézu správně zamítli. Vyšší síle obvykle pomáhá:

- větší skutečná velikost efektu;
- více nezávislých lokalit;
- menší variabilita a tím menší standardní chyba;
- méně přísné rozhodovací pravidlo — za cenu vyššího rizika chyby I. druhu.

Nízká síla znamená, že častěji nastane chyba II. druhu: reálný vztah přehlédneme. Proto **nezamítnutí nulové hypotézy není důkazem nulového efektu**, zvláště u malé nebo velmi variabilní studie. Rozhodovací hranici $\alpha = 0,05$ už máme, takže teď můžeme sílu ukázat také číselně.

11.4 Vraťme se k síle: kolik studií vztah odhalí?

Teď už máme rozhodovací hranici $\alpha = 0,05$, takže můžeme dokončit číselný příklad síly testu. Musíme si nejprve zvolit **konkrétní skutečný efekt**, který chceme umět odhalit. Začneme vztahem 0.25 mm na jeden stupeň — přibližně polovinou sklonu pozorovaného u krabů. Ptáme se

tak, zda by stejná studie dokázala zachytit i slabší, ale předem zvolený vztah. Nakonec výsledek porovnáme také s naším pozorovaným sklonem.

Vytvoříme 5000 hypotetických studií. Každá bude mít stejných třináct zeměpisných šířek jako naše data. Do každé vložíme skutečný sklon 0.25 mm na stupeň a přidáme náhodná residua podobně velká jako v našem modelu. Potom vždy fitujeme přímkou a zaznamenáme, zda při $\alpha = 0,05$ zamítla nulový sklon.

Co jsme v příkladu nastavili	Hodnota
Skutečný sklon, který chceme odhalit	0.25 mm na 1°
Počet lokalit v každé studii	13
Velikost náhodných residuí	přibližně 1.23 mm
Rozhodovací hranice	$\alpha = 0.05$
Studie, které nulový sklon zamítly	4077 z 5000

V tomto **ilustračním scénáři** tedy vyšla síla přibližně

$$\text{odhad síly testu} = \frac{\text{počet studií, které zamítly nulový sklon}}{\text{počet všech simulovaných studií}}.$$

$$\frac{4077}{5000} = 0.815 \approx 81.5 \, \%.$$

Zkráceně bychom stejný výpočet mohli zapsat jako

$$\widehat{\text{síla}} = \frac{m}{N},$$

kde m je počet simulovaných studií, které nulový sklon zamítly, a N je počet všech simulovaných studií.

To znamená: kdyby byl skutečný sklon 0,25 mm na stupeň a všechny ostatní podmínky odpovídaly této simulaci, přibližně 81.5 % stejně navržených studií by při $\alpha = 0,05$ nulový sklon zamítlo. Zbylé studie by tento skutečný vztah přehlédly – dopustily by se chyby II. druhu.

Porovnání s naším odhadnutým sklonem

Když do stejné simulace vložíme sklon 0.49 mm na stupeň, který jsme odhadli z krabích dat, nulový sklon zamítne 4999 z 5000 studií. Odhad síly je tedy přibližně 99.98 %. Je vyšší než u sklonu 0,25 mm na stupeň, protože větší skutečný efekt je při stejném počtu lokalit a stejné variabilitě snazší odhalit.

Změňte scénář v hlavě

Co by se podle vás stalo se silou, kdyby byl skutečný sklon menší? Co kdybychom měli více nezávislých lokalit nebo menší residua?

Těchto 81.5 % **není pravděpodobnost, že je náš závěr pravdivý**, ani dodatečné hodnocení pozorovaného p-výsledku. Je to vlastnost předem popsaného hypotetického scénáře. Formální plánování síly a potřebné velikosti výběru necháme na pozdější kurz.

12 Co tedy můžeme říct o krabech?

Vraťme se k původní otázce.

Dokázali jsme, že severněji žijící krabi jsou větší?

Ne. Máme silný a dobře popsany výsledek pro třináct sledovaných slanisek a jednoduchý model. To není totéž jako definitivní důkaz obecného biologického pravidla.

Která výsledková věta vám řekne více?

Porovnejte dva závěry:

A: „ $p < 0,05$, proto jsou severní krabi větší.“

B: „Odhad sklonu říká, že průměrná šířka krunýře rostla přibližně o 0.49 mm na stupeň; interval od 0.315 do 0.664 mm ukazuje, jak velký vztah je s daty slučitelný.“

Která věta vám o krabech řekne více? Co je špatně ve větě A? Co ještě chybí i ve větě B?

Úplný závěr můžeme poskládat z následujících odpovědí:

Nejprve se ptáme	Odpověď v krabím příběhu
Jak velký je vztah?	0.49 mm na 1°; 2.45 mm na 5°
Je biologicky zajímavý?	Přes sledovaný rozsah odpovídá asi 6.22 mm
Jak přesný je odhad?	95% CI [0.315; 0.664] mm na 1°
Jak dobře se data shodují s nulovým sklonem?	$t \approx 6.16$, $df = 11$, $p \approx 0.000071$
Jaké je rozhodnutí při $\alpha = 0,05$?	výsledek je statisticky významný; nulovou hypotézu zamítáme
Co ještě může závěr omezovat?	výběr lokalit, prostorová závislost, agregace a jednoduchost modelu

Vaše verze — Vysvětlete výsledek biologovi

Napište pět až šest vět tak, aby čtenář nejprve pochopil, **co se s velikostí krabů mění a o kolik**. Potom přidejte nejistotu, srovnání s nulovým sklonem a nakonec omezení toho, co lze z těchto třinácti slanisek zobecnit.

Jedna možná odpověď:

Příklad úplného výsledku

Na 13 sledovaných slaniskách atlantského pobřeží se průměrná šířka krunýře samců zvyšovala přibližně o 0.49 mm na každý stupeň zeměpisné šířky, tedy asi o 2.45 mm na 5°. Přes celý sledovaný rozsah odpovídá fitovaná přímka změně přibližně 6.22 mm, která je vzhledem k velikosti krabů biologicky zajímavá. 95% interval spolehlivosti sahal od 0.315 do 0.664 mm na stupeň. Při hladině $\alpha = 0,05$ byl výsledek statisticky významný; při předpokladech jednoduchého lineárního modelu byla data obtížně slučitelná s přesně nulovým sklonem ($t \approx 6.16$, $df = 11$, $p \approx 0.000071$). Výsledek podporuje kladný vztah mezi zeměpisnou šířkou a průměrnou velikostí samců na sledovaných slaniskách, ale sám neprokazuje, že zeměpisná šířka velikost krabů způsobuje.

12.1 Co se do jedné přímky nevešlo

Diagnostické grafy jsme prohlédli hned po fitování modelu. Ani dobrý diagnostický obraz ale neřeší všechna omezení studie a zvoleného modelu:

- **Jsou všechna slaniska stejně dobře změřena?** Ne úplně. Počty krabů se mírně liší, takže průměry nemají stejnou přesnost. Jednoduchá nevážená regrese jim přesto dává stejnou váhu.
- **Co se stalo s rozdíly mezi jednotlivými kraby?** Zprůměrováním jsme je z hlavní analýzy odstranili. Pro dnešní otázku to bylo užitečné, ale část informace jsme ztratili.
- **Nestojí přímka hlavně na několika lokalitách?** Dvě nejjižnější lokality mají poměrně velký vliv. Když však postupně vynecháme vždy jednu lokalitu, všechny sklony zůstávají kladné a leží přibližně mezi 0.429 a 0.559 mm na stupeň.
- **Mohou si blízká slaniska být podobnější?** Ano. Geografické lokality nemusí být zcela nezávislé a přímka není úplný prostorový ekologický model.
- **Dokazuje vztah příčinu?** Ne. Studie je observační. Zeměpisná šířka může souviset s teplotou, délkou sezóny i dalšími podmínkami.

Kvůli těmto omezením nemusíme výsledek zahodit. Musíme ale být opatrní, když ho zobecňujeme na jiná místa, populace nebo biologické mechanismy.

13 Měsíc pořád není ze syra

P-hodnota nám neřekne pravděpodobnost, že je Měsíc ze syra. Stejně tak nám neřekne pravděpodobnost, že je Bergmannovo pravidlo pravdivé.

Odpovídá na mnohem užší otázku: **Jak neobvyklá by byla naše testová statistika, kdyby platilo přesně zvolené nulové tvrzení a předpoklady modelu?**

Vědecký závěr vzniká spojením více částí:

- velikosti efektu;
- biologického významu;
- nejistoty;
- slučitelnosti s konkrétním nulovým tvrzením;
- uspořádání studie;
- předpokladů a možných chyb;
- dosavadních znalostí a dalších studií.

Hlavní myšlenka lekce

Věda nezískává pravdu z $p < 0,05$. Staví opatrné a opravitelné závěry z efektu, nejistoty, kvality studie a souvislostí.

14 Příště budeme porovnávat skupiny

Zeměpisná šířka byla číselný prediktor, a proto jsme vztah popisovali sklonem. Příště nebude prediktorem číslo, ale příslušnost ke skupině, například kontrola a zásah. Místo sklonu se budeme ptát na rozdíl mezi dvěma průměry.

Způsob uvažování zůstane stejný: nejprve velikost a biologický význam rozdílu, potom nejistota, srovnání s přesnou nulou a nakonec omezení studie.

15 Co si odnést

- Testovatelnost tvrzení není totéž jako jeho věrohodnost.
- Nulový sklon znamená žádný **systematický lineární trend**, nikoli žádnou náhodnou variabilitu mezi lokalitami.
- T-statistika měří vzdálenost od nulového sklonu ve standardních chybách.
- Stupně volnosti určují, kterou referenční t-křivku použijeme a kolik plochy zůstává daleko od nuly.
- P-hodnota je podmíněná plocha v chvostech referenčního rozdělení, nikoli pravděpodobnost pravdivosti hypotézy.
- „Statisticky významný“ je výsledek rozhodovacího pravidla; neznamená automaticky velký nebo biologicky důležitý efekt.
- Zamítnutí i nezamítnutí nulové hypotézy může být chybné a závažnost obou chyb závisí na jejich důsledcích.
- Síla testu popisuje schopnost odhalit předem zvolenou skutečnou velikost efektu; nízká síla zvyšuje riziko, že reálný vztah přehlédneme.
- Dobrá vědecká odpověď spojuje velikost vztahu, nejistotu, srovnání s přesnou nulou, diagnostiku modelu a omezení studie.

Slovníček pojmů

Pojmy použité v těchto materiálech a jejich definice. Úplný průběžně aktualizovaný slovníček je dostupný také [online](#).

Interaktivní slovníček je dostupný online: <https://cuni-natur-biostatistics.github.io/slovník/>